

初版AL prd

Alienlearn 产品需求文档 (PRD) - v0.1 MVP版

1. 产品概述 (Product Overview)

1.1 产品定位

一款由 LLM-Agent 驱动的“外星人潜伏地球”主题沉浸式外语语境沙盘。结合微缩像素箱庭与现代 Web 动态交互，将无聊的“语言学习”转化为硬核的“情报获取与伪装生存”游戏。

1.2 目标用户

- 对传统语言学习 App（如 Duolingo）感到枯燥，渴望真实语境对练的用户。
- 喜爱 CRPG、跑团或《极乐迪斯科》等重度叙事与角色扮演的玩家。
- 对二次元抽卡、赛博朋克/故障艺术美学有偏好的年轻群体。

1.3 核心世界观 (Lore)

地球已被全息数据化，化作无数个“全息玫瑰碎片（Holographic Fragments）”。玩家作为潜伏地球的外星人，必须戴上不同的人类“面具（Masks）”，接入这些碎片（如雨夜拉面馆），通过与地球人（AI NPC）交谈来学习语言、窃取情报。语言越地道，全息伪装越稳定；一旦胡言乱语，系统将触发 Glitch 甚至崩溃。

2. 核心系统架构 (Core Architecture)

作为独立开发项目，系统必须高度解耦，确保前端表现极轻量，核心逻辑收敛于后端。

层级	技术栈/选型	核心职责
表现层 (Frontend)	微缩像素引擎 + WebGL/ Canvas/SVG UI	渲染极简空间锚点（10x10 箱庭场景）；呈现战术 HUD、流式对话框及 Glitch 视觉特效；拦截用户输入。
逻辑层 (Backend)	Python + FastAPI + Redis	处理高并发长连接（SSE 流式传输）；管理全服玩家体力与面具状态；执行基础业务逻辑。
智能层 (AgentOps)	LangGraph + 商业 API (GPT-4o-mini 等)	意图路由分类；NPC 状态机流转；动态生成结构化回复（情绪、行为意图、纠错反馈）。

3. MVP 核心功能规格 (Feature Specifications)

3.1 视觉与空间容器 (Diorama & HUD)

- **箱庭展示**：使用极简 16x16 或 32x32 像素构建单屏幕微型场景（如：一间拉面馆）。NPC 在设定好的节点（Waypoints）上待机或执行简单意图动画。
- **战术情报面板 (HUD)**：
 - **状态条**：显示当前“伪装维持度 (Suspicion Level)”和“全息能量 (Energy/Token)”。
 - **对话终端**：占据屏幕主视觉，采用打字机效果呈现 NPC 对话。
 - **面具档案**：展示当前佩戴的身份面具及其附带的语言 Buff。
- **动态特效反馈 (Generative UI)**：前端根据后端的结构化输出实时改变环境。如 `{"emotion": "angry"}` 触发屏幕边缘泛红与屏幕震动。

3.2 AI 对话与状态流转系统 (The Core Loop)

整个体验的 90% 发生在此环节。后端通过 LangGraph 将对话切分为离散节点。

- **多智能体协作管线**：
 - 意图路由器 (Router Agent)**：玩家输入文字后，Router 率先判定意图是否属于当前场景 (In-Scope/Out-of-Scope)。
 - 教务智能体 (Pedagogy Agent)**：并行检查玩家语法的准确性，生成 `grammar_feedback` 字段和高亮纠错坐标。
 - 角色演绎体 (Persona Agent)**：基于前两个 Agent 的结果和当前的业务状态机（如：进店 $\rightarrow$ 点餐 $\rightarrow$ 闲聊），生成符合人设的最终回复与行为意图。
- **状态持久化**：NPC 拥有基于当前 Session 的短时记忆 (Memory Stream)，能记住玩家上两轮说过的关键信息（如玩家谎称自己是学生）。

3.3 异常话题防御机制 (Jailbreak Defense)

采用三层“软硬兼施”的防御网，将出戏行为转化为游戏体验：

- 软回弹 (Persona Defense)**：识别到异常话题时，NPC 以其设定的性格强烈拒绝并强行拉回主线（例：暴躁老板拒聊量子物理）。
- 视觉惩罚 (Visual Glitch)**：前端触发轻微的 CSS 色差分离或静态噪点，警告玩家“伪装开始失效”。
- 硬崩溃 (System Reset)**：连续三次偏离主题，触发剧情强制中断，弹回主界面并扣除全息能量。

4. 商业化路径 (Monetization Strategy - Phase 1)

MVP 阶段不包含复杂的 SFT 训练与抽卡机制，以最快速度跑通现金流。

- **体力限制与恢复 (Energy System)**：
 - 玩家的每一次交互消耗“全息能量”（变相覆盖 API Token 成本）。
 - 提供每日免费基础能量池；耗尽后可观看广告恢复。

- 高级地球签证 (Subscription Premium):
 - 包月制（例：\$9.9/月）。
 - 特权：无限全息能量；解锁深度的母语级语法解析浮窗；免疫一次“硬崩溃”惩罚。
- 场景扩充包 (DLC Packs):
 - 基础版本免费提供“新手村”场景（如：拉面馆）。
 - 单次付费解锁高级沉浸场景（如：秋叶原女仆咖啡厅、新宿深夜酒吧、警署盘问室），附带特定的高级语言挑战。

5. AgentOps 与自动化评测 (Evaluation Metrics)

为后续接入 UGC 生态和微调私有模型打好数据地基。系统需建立自动化的 LLM-as-a-Judge 评测流水线。

- 红蓝对抗测试机：上线新 NPC 前，系统自动生成“正常通关”、“极差语法”、“刻意越狱”三种对话 Trace 进行黑盒测试。
- 层级化评分指标 (1-5分):
 - 角色一致性 (Persona Consistency)：拒绝大模型口音，严格遵循情绪与身份设定。
 - 教学遵循度 (Pedagogy Compliance)：遇到语病必须触发纠正机制，且不被玩家母语带偏。
 - 路由准确率 (Routing Accuracy)：能否精准判断对话在业务状态机中的位置。

6. MVP 开发排期建议 (Milestone Roadmap)

阶段	核心任务	预期交付物
Phase 1: 核心引擎 (Week 1-2)	跑通 FastAPI + LangGraph 后端；完成 Router 与 Persona Agent 的基础通信；定义 JSON 结构化输出。	可在终端运行的纯文本对话 Demo， 馈。
Phase 2: 表现渲染 (Week 3-4)	搭建前端环境（Godot / Web）；实现基础微缩像素场景渲染；完成 SVG/Canvas 驱动的对话终端与特效联动。	前后端连通，实现流式打字效果与 G
Phase 3: 场景与闭环 (Week 5-6)	编写“拉面馆”完整剧本状态机；对接商业化 API 限制逻辑；接入基础自动化 Eval 工具。	包含完整闭环的 v0.1 版本，可向核心

这份更新后的 PRD（v0.2 版）剥离了表层的“功能堆砌”，将上一轮对于护城河、数据飞轮、长期留存和评测指标的战略推演正式沉淀为工程和业务蓝图。

同时，正如你所强调的，我们在文档末尾专门新增了【数据验证计划 (Empirical Validation Plan)】，确保所有的直觉设计（Design Intuition）在 MVP 上线后都能通过真实的埋点数据来进行证伪或放大。

Alienlearn 产品需求文档 (PRD) - v0.2 核心壁垒与验证版

7. 产品定位与魔法时刻 (Product Moat & Magic Moment)

1.1 核心定义 (What we are)

Alienlearn 不是“对话生成器”，而是基于 LLM-Agent 架构的“高压语言社会工程学模拟器”。

我们利用 AI 不是为了发散对话 (Generation)，而是为了提供状态管理与动态约束 (State Management & Constraint)。产品将“背错单词的挫败感”转化为“潜伏暴露的危机感”，为用户提供真实语境下的社交后果模拟。

1.2 魔法时刻 (The Magic Moment)

玩家在“雨夜居酒屋”使用错误的量词点餐。系统没有弹出“Teacher AI”的红色错号，而是触发了环境异变：雨声瞬间变大，老板立绘发生轻微红蓝错位 (Glitch)，并用关西腔严厉反问。同时，UI 侧边栏像情报解密一样，静默滑出正确的语法纠错数据流。

体验内核：玩家在这一刻忘记了“我在学外语”，只剩下“我必须用正确的语法圆回来，维持伪装”的生存本能。

2. 核心循环与长期留存 (Core Loop & Retention)

2.1 长期留存驱动力：面具特权与文化碎片收集

解决“用户明天为什么回来”的核心机制，不依赖消耗性的线性剧情，而依赖**身份与场景的交叉解锁**。

- 资源积累：**玩家在基础节点（如拉面馆）中输出正确的语言，维持全息稳定度，积累“情报值”。
- 面具抽卡/解锁 (Mask Gacha)：**消耗情报值获取新的 Persona Mask（如：“职场老油条”、“涉谷辣妹”）。
- 权限验证：**高级场景（如“东京商务谈判桌”）具有门槛，玩家必须佩戴特定面具、且具备更高的词汇池才能存活，形成“学习 → 生存 → 解锁新身份 → 挑战新语境”的闭环。

3. AgentOps 架构与交互层 (Architecture & Frontend)

3.1 极简视觉容器 (16x16 Micro-Diorama)

- 存在理由：**前端的像素箱庭并非为了提供“跑图玩法”，而是提供**零认知成本的空间锚点** (Visual Context)。它免去了用户“想象我在哪”的脑力消耗，将玩家注意力和系统 Token 预算 100% 锁定在语言博弈上。

3.2 多智能体解耦与防越狱 (Multi-Agent Decoupling)

摒弃单一大模型 Prompt，采用 LangGraph 编排的专职 Agent 架构，以换取极高的控制力和评测颗粒度：

- Router Agent (意图防线)：**执行严格的意图二分类与 Semantic Drift（语义漂移）拦截。

2. **Pedagogy Agent (教务引擎)**: 专职检测语言瑕疵，输出纯粹的结构化 `grammar_feedback`。

3. **Persona Agent (角色演绎)**: 接收前两者的指令，合成符合人设的文本与前端驱动情绪指令 (Emotion/Action)。

4. 商业护城河：数据飞轮与评测体系 (Data Engine & Eval)

Alienlearn 的终极壁垒不在于调用了什么模型，而在于沉淀出一条 OpenAI 等通用底座无法获取的**垂直评测与微调管线**。

4.1 核心数据资产 (Proprietary Data)

我们收集的不是“聊天记录”，而是“特定 Persona 下的语言学习者思维链与纠错轨迹 (Pedagogical Trace)”。

- 数据结构: [玩家错误上下文] -> [意图路由日志] -> [结构化语法纠错] -> [带有人设情绪的反馈合成]。

4.2 LLM-as-a-Judge 自动化评测 (Automated Eval)

为保障 UGC 场景质量，系统内置红蓝对抗评测器，对 NPC 进行多维度打分：

- **人设稳定性 (Persona Consistency)**: 是否有“AI 说教味”或脱离背景设定。
- **教学遵循度 (Pedagogy Compliance)**: 面对母语混合输入或糟糕语法，能否稳定触发纠错机制。

这套管线在 MVP 后期，将直接转化为“两阶段微调 (Two-Stage SFT)”的高质量语料，用于训练成本极低、专精于结构化角色扮演的私有小参数模型。

5. 北极星指标与数据验证计划 (Empirical Validation Plan)

目前的系统设计均基于产品直觉。MVP (v0.1) 上线后，必须通过以下真实埋点数据来验证或推翻假设：

5.1 北极星指标 (North Star Metric)

- **自发目标语言输出率 (Voluntary Target Language Output per Session)**:
- 单次 Session 内，玩家主动输入的目标语言有效词汇量/长句数量的增长曲线。此指标直接证明产品是否起到了“语言驱动”作用。

5.2 核心直觉的埋点验证 (Hypothesis Testing)

1. 验证 Agent 架构的必要性：

- **数据指标**: 监测 Router Agent 在识别“脱离语境 (Out-of-Scope)”输入时的准确率和拦截率；监测 Persona Agent 的“人设越狱成功率”。
- **判定标准**: 如果拦截成功率低于 90%，说明解耦带来的 Latency 成本不划算，需要重新优化意图树。

2. 验证“动态 UI 纠错”的容忍度：

- **数据指标：**玩家触发 `grammar_feedback` (全息崩溃/战术 HUD 纠错) 后的**次日留存率** vs 未触发该机制玩家的留存率。
- **判定标准：**如果频繁被纠错的玩家流失率极高，说明当前的 Glitch 惩罚机制在“娱乐”与“学习”的平衡上失准（过重），需要调优表现形式。

3. 验证视觉容器 (Pixel UI) 的 ROI:

- **数据指标：**监控玩家在“无微缩场景纯对话模式”与“16x16 箱庭模式”下的平均 Session 时长对比（可做小范围 A/B Test）。
- **判定标准：**用数据量化 Pixel 空间锚点对沉浸感和停留时长的真实贡献。