

合规思考

这是一个非常敏锐且专业的 PM 嗅觉！在 UGC 和大模型（LLM）双重加持下，“真实世界设定”确实是一个巨大的合规雷区。

当玩家拥有自由输入和创造的权利时，真实地理和文化背景极易引发以下风险：

- 1. 政治与地缘敏感：**UGC 创作者可能会在真实城市中植入争议性的政治事件或敏感人物。
- 2. 宗教与文化禁忌：**比如在阿拉伯语文化圈或中东场景中，模型轻微的幻觉（Hallucination）或玩家的恶意引导，都可能触碰严重的宗教红线，导致产品被直接下架。
- 3. 刻板印象与偏见（Bias）：**如果底层模型没有做好对齐，NPC 可能会对特定国家、种族输出带有歧视性的刻板印象。

为了让 Alienlearn 既能保留“跨文化探索”的魅力，又能规避这些致命风险，我们需要从“世界观包装（产品侧）”和“AI 安全架构（技术侧）”双管齐下。

一、世界观包装方案（产品侧解法）

不要直接使用“现实地球的一比一复刻”，我们需要给真实世界上加一层“科幻滤镜”，建立防火墙。

方案 A：全息玫瑰碎片（镜像地球设定）

- 设定：**外星人探索的不是当下的真实地球，而是基于历史数据生成的“地球文明全息碎片（Holographic Fragments）”。这些碎片由于数据损坏或外星认知差异，与真实世界存在偏差。
- 做法：**对真实地名和设定进行“模糊化”或“异化”处理。比如不叫“纽约”，而是“大苹果星区”；不叫“东京”，而是“霓虹岛枢纽”。这样即使出现不合常理或略带争议的剧情，也可以用“全息数据在重构时发生了错乱”来完美圆过去，剥离了现实政治属性。

方案 B：平行时空 / 错位时代设定

- 设定：**切断与“现代真实社会”的联系，将场景锁定在特定的、已无政治争议的历史切片或复古未来主义（Retro-futurism）中。
- 做法：**比如玩家体验的是“1920年代的巴黎”、“赛博朋克风的未来开罗”或是“维多利亚时代的伦敦”。脱离了当下的地缘政治语境，敏感度会大幅下降。

方案 C：模块化架空都市

- 设定：**UGC 创作者不能直接在真实地球仪上“插旗”，而是只能在一个架空的“大都会（Metropolis）”中购买街区。
- 做法：**创作者可以为自己的街区赋予某种现实文化的“风情”（比如“中华小吃街”、“法式浪漫区”），但地理位置是架空的。

二、大模型安全与意图控制（技术侧解法）

作为 AI 驱动的产品，仅靠世界观掩护是不够的，底层的机制必须做到绝对可控。

1. 独立的安全守门员 (Safety/AgentOps 机制)

在我们的多智能体（Multi-agent）框架中，必须单独拉起一个**合规审核 Agent**。

- 当 UGC 创作者提交一个新场景（输入 Prompt）时，合规 Agent 优先拦截，扫描是否包含政治、暴恐、色情意图。
- 在实时对话中，当玩家试图用敏感词“越狱（Jailbreak）”引导 NPC 时，合规 Agent 必须具备打断能力，强制触发 NPC 的“防御性回复”（例如：“抱歉，我的外星翻译器似乎发生故障，无法理解这个词汇，我们还是继续聊聊这杯咖啡吧”），确保 NPC 不破防、不崩人设。

2. 两阶段评测与对齐管线 (Evaluation & Alignment)

模型上线前，我们需要构建一套极其严苛的自动化评测集。

- 建立**层级化打分数据集（Hierarchical Scoring Datasets）**，专门针对“文化偏见”、“政治诱导”、“宗教禁忌”等维度对基础模型进行红蓝对抗（Red-teaming）。
- 通过两阶段的微调管线（例如先做 SFT 确保角色扮演能力，再通过 DPO/RLHF 强化人类价值观对齐），确保即使玩家恶意引导，模型的输出依然收敛在安全边界内。

3. 知识库白名单制 (RAG Guardrails)

UGC 创建场景时，系统不完全依赖大模型的内部知识库（这往往包含不可控的训练脏数据），而是采用**白名单检索增强（Whitelist RAG）**。玩家想生成一个“开罗街市”，系统会从官方预先审核过的“安全文化图鉴向量库”中提取风俗、美食数据来辅助生成，从源头上切断有害信息的注入。

通过“全息数据碎片/架空都市”的世界观隔离，配合底层强大的“多智能体合规巡逻 + 评测管线”，Alienlearn 就能在保持高度自由的文化体验的同时，完美规避现实合规风险。